

02 ggplot2绘图基础

数据如何改变战争？基于南丁格尔玫瑰图的可视化项目

目录

项目背景

项目任务

项目总结

新知探究

项目任务（续）

项目背景

项目背景 新知探究 项目任务 项目总结

1854 年，克里米亚战争爆发。在当时的公众认知里，士兵的生命结束于战场——被子弹击中，因伤口恶化。

随军护士**弗洛伦丝·南丁格尔**抵达斯库塔里战地医院后，看到的却是另一个战场：没有冲锋号，只有拥挤、污秽、疾病蔓延的病区，和接二连三倒下、来不及被抬上病床的士兵。

她整理了 1854 年 4 月至 1856 年 3 月共 **24 个月**的英军伤亡数据。

先凭直觉投票

- A 战伤
- B 可预防疾病
- C 其他原因
- D 需要数据，暂时无法判断

先保留判断，随后用数据检验。

【先想一想】本项目的第一个问题

士兵主要死于**战伤**，还是死于**本可预防的疾病**？

我的判断是：_____ 我的理由是：_____

1855 年 3 月，英国政府派出卫生委员会实施基础卫生工程：清理粪坑与污水池、冲洗堵塞的下水道、清除污染水源的动物尸体、改善通风与病房拥挤。

1858 年，南丁格尔在《影响英军健康、效率与医院管理的笔记》中发表了这样一张图：


- **两个并排的扇形图** = 卫生改革前后各 12 个月
- 每个月的**扇形面积** = 该月的死亡水平
- **颜色** = 三类死亡原因

这张图后来被称为「南丁格尔玫瑰图」（极区图）

它让没有统计学基础的议员和公众**一眼看懂**：士兵死亡的主要来源不是战斗。这张图成为推动军队卫生改革与战地医院改造的重要证据之一。

可视化不只是把数字画出来，而是让证据被看见。

本项目要交给政府的，就是这样一份“**让证据被看见**”的报告。最后一节课，我们会亲手把它复刻出来：



同一份数据，两种表达：本项目的全部任务，都是为了回答“哪一个更能支持决策”。

你是一名**军队卫生改革数据顾问**。
政府需要决定：有限的资源，应该优先用于战伤救治，还是用于改善医院与营地的卫生条件？

驱动性问题
数据能否为卫生改革的资源投入提供可信证据？

项目成果：

成果	要求
4 幅证据图	分别服务于 4 个不同的分析问题
1 段图表解读	按“结论—证据—建议—局限”组织
1 项行动建议	面向公共卫生决策，并说明结论的边界

数据来源： `HistData::Nightingale`（南丁格尔记录并整理的英军月度伤亡数据），1854 年 4 月—1856 年 3 月，共 24 个月。

内容	本项目约定
研究范围	本数据记录的英军，共 24 个月
改革前	1854 年 4 月—1855 年 3 月（12 个月）
改革后	1855 年 4 月—1856 年 3 月（12 个月）
死亡原因	可预防疾病、战伤、其他原因
月份顺序	两个阶段均按 4 月 → 次年 3 月排列，便于逐月对比
军队人数	当月英军平均人数的估计值，是计算死亡率的分母

为什么必须用「率」而不是「人数」？

军队人数在 24 个月里不断变化。只看死亡人数，会把“士兵多所以死得多”误当成“风险高”。

变量	含义	类型 / 单位
日期	观测月份，1854-04 至 1856-03	时间
月份	4 月 → 次年 3 月，已按战争时间顺序排列	分类
军队人数	当月英军平均人数	数值 / 人
阶段	改革前 / 改革后	分类
死亡原因	可预防疾病 / 战伤 / 其他原因	分类
死亡人数	当月因该类原因死亡的人数	数值 / 人
死亡率	年化死亡率	数值 / 每千人年
死因类别	大致含义	
可预防疾病	霍乱、痢疾、斑疹伤寒等与卫生条件密切相关的传染病	
战伤	在战斗中受伤并因此死亡	
其他原因	意外、其他疾病等	

我们手里有两个可以画的指标：

指标	含义	适合回答的问题
死亡人数	某段时间因某类原因死亡的人数	哪一类死因造成的死亡 负担 最重？
年化死亡率	$\text{年化死亡率} = 12 \times 1000 \times \frac{\text{死亡人数}}{\text{军队人数}}$	死亡 风险 有多高？

【先想一想】

1. 要比较三类死因“谁造成的死亡负担最重”，应该用哪个指标？为什么？

2. 要比较“哪个月的死亡风险更高”，又该用哪个指标？为什么？

我的判断：_____

我的理由：_____

【参考答案】

1. 比较“负担”用死亡人数。

“负担”问的是“死了多少人”，死亡人数含义直观，直接相加就能得到 12 个月的累计规模。它不需要理解分母。

2. 比较“风险”用年化死亡率。

不同月份的军队人数不同。年化死亡率把分母（军队人数）考虑进来，表示“每千人年”的死亡风险，**跨月份、跨阶段才可比**。缺点是概念需要解释，单位（每千人年）必须讲清楚。

本项目据此分工：

任务	使用的指标	回答的问题
任务 1	累计死亡人数	死亡负担主要由哪类原因造成
任务 2—4	年化死亡率	死亡风险有多高、如何变化

原始数据是**宽表**：一行一个月，三类死因的人数与死亡率各占一列。绘图需要的是**长表**：一行 = 某月 × 某类死因。

```
1 library(tidyverse)
2 library(HistData)
3
4 nightingale <- HistData::Nightingale
5
6 nightingale_long <- nightingale %>%
7   mutate(阶段 = factor(rep(c("改革前", "改革后"), each = 12),
8                        levels = c("改革前", "改革后"))) %>%
9   rename(Disease.count = Disease, Wounds.count = Wounds, Other.count = Other) %>%
10  pivot_longer(
11    cols = c(Disease.count, Wounds.count, Other.count,
12             Disease.rate, Wounds.rate, Other.rate),
13    names_to = c("死亡原因", ".value"), names_sep = "\\."
14  )
```

```
1 nightingale_long <- nightingale_long %>%
2   rename(日期 = Date, 年份 = Year, 军队人数 = Army,
3         死亡人数 = count, 死亡率 = rate) %>%
4   mutate(
5     月份 = factor(as.integer(format(日期, "%m")),
6                   levels = c(4:12, 1:3),
7                   labels = paste0(c(4:12, 1:3), "月")),
8     死亡原因 = factor(
9       recode(死亡原因, "Disease" = "可预防疾病",
10              "Wounds" = "战伤", "Other" = "其他原因"),
11       levels = c("可预防疾病", "战伤", "其他原因"))
12   )
```

数据框	在项目中的作用
nightingale_long	全部长表（72 行 = 24 月 × 3 类死因），任务 3、任务 4 使用
before	改革前 12 个月，任务 1、任务 2 与巩固提升使用
after	改革后 12 个月，备用

数据处理代码已全部给出：本项目要练的是“从分析目的出发选图、画图、读图”，不是数据清洗。

完成本项目后，我能够：

- 从真实问题中提取**分析目的**，并确定需要比较的变量与指标
- 建立「**变量** → **视觉通道**」的映射关系，独立完成证据图
- 用 `ggplot()`、`aes()`、`geom_col()`、`labs()`、`facet_wrap()`、`coord_polar()`、`scale_y_sqrt()` 组合出所需图形
- 区分「**变量映射**」与「**属性设定**」
- 按「**结论—证据—建议—局限**」解读图表，并说明结论的边界
- 在 AI 辅助环境中保持对数据、代码和结论的**主体判断**

本项目不是” 老师讲一个函数、你模仿一段代码” ， 而是围绕一个真实问题不断追问：



【先想一想】补全这条链

备选：认识数据 / 明确分析目的 / 构建图形 / 形成建议

位置	我认为应填入的环节	这个环节要回答什么问题
①	_____	_____
④	_____	_____
⑥	_____	_____

真实问题 → ① 明确分析目的 → ② 选择指标 → ③ 建立映射 → ④ 构建图形 → ⑤ 解读证据 → ⑥ 形成建议

位置	应填入的环节	要回答的问题	本项目对应
①	明确分析目的	要回答什么问题？	驱动性问题
②	选择指标	用什么数据回答？	人数 / 年化死亡率
③	建立映射	变量映射到哪？	映射表
④	构建图形	用什么图层画？	ggplot2 代码
⑤	解读证据	证据在哪里？	图表解读
⑥	形成建议	话能说到什么程度？	决策建议与局限

这条链的用法

每解决一个问题，就形成一项新的项目成果。 如果你在 ⑤ 发现图形答不出问题，就要回到 ②③④ 修改，而不是继续往下做。

课时	任务	当前问题	阶段成果
第一课时	任务 1	哪一类死亡原因造成的死亡 负担 最重？	累计死亡人数对比图
第一课时	任务 2	高死亡水平是否 集中 在个别月份 ？	月度堆叠柱形图
第一课时	巩固提升	三类死因的月度变化是否一致？怎样改进表达？	★ / ★★ / ★★★ 三星任务
第二课时	任务 3	卫生改革前后 发生了 什么变化 ？	按阶段分面对比图
第二课时	任务 4	玫瑰图适合 分析 还是 传播 ？	玫瑰图与评价
项目结论	总结	证据支持怎样的行动建议？	决策建议与局限

问题牵引 数据探究 图形建构 证据解读 决策反思

课时	核心任务	新知支撑	课堂产出
第一课时	任务 1、任务 2、巩固提升	视觉通道、图形映射、ggplot2 基本语法、统一配色	比较图、月度构成图
第二课时	任务 3、任务 4	分面、极坐标与面积编码、图形选择	分面对比图、玫瑰图评价

每个任务遵循同一条实践路线（也是课堂子导航的四个环节）：

分析目的 数据映射 图形建构 图表解读

分层要求：★ 基础必做 ★★ 进阶选做 ★★★ 挑战合作

节奏提示：新知探究的「分面」「极坐标与面积编码」两节属于第二课时内容，可放在第二课时开头回看。

新知探究

项目背景 新知探究 项目任务 项目总结

数据变量必须通过**视觉通道**才能进入图形。

视觉通道	人眼感知特点	适合的数据	本项目示例
位置	最精确，可读出高低、左右	数值、类别、时间	月份、累计死亡人数
长度	很精确，可直接比较长短	数值	柱形高度、年化死亡率
角度 / 面积	较粗略，容易被夸大	数值	玫瑰图中的扇形
颜色（色相）	擅长区分 类别 ，不擅长比较大小	分类	死亡原因
分面	把整体拆成结构相同的小图	分类	改革前 / 改革后

【先想一想】

如果我的目的是” **精确比较**三类死因的死亡水平” ，应该优先使用哪两个视觉通道？

我的选择：_____ 理由是：_____

【参考答案】优先使用「位置」和「长度」

位置和长度是最精确的通道：柱高与数值成**线性关系**，读者可以直接读出高低和差值。

角度、面积、颜色都不适合精确比较：扇形面积与半径是**平方关系**，读者很容易把差异看成数值的倍数；颜色擅长区分“是哪一个”，不擅长回答“大多少”。

一句话原则：要精确比较，用位置和长度；要用颜色，就让颜色只管分类。

这也是本项目的图形分工：

我要回答的问题	主要通道	图形
哪类死因负担最重	长度（柱高）	柱形图
哪几个月风险最高	位置（月份先后） + 长度	堆叠柱形图
改革前后怎样变化	分面 + 长度	分面柱形图
怎样让公众一眼看懂	角度 / 面积	玫瑰图

ggplot2 用“ **数据 + 映射 + 图层**”逐步建构图形。

```
1 ggplot(data = 数据框,  
2         aes(x = 横轴变量,  
3             y = 纵轴变量,  
4             fill = 分类变量)) +  
5   geom_几何对象() +      # 柱、点、线等  
6   stat_统计变换() +      # 计数、汇总等（可选）  
7   scale_标度() +         # 颜色、坐标刻度等  
8   facet_分面() +         # 分组比较  
9   coord_坐标系() +      # 直角或极坐标  
10  labs(...) +            # 标题、轴名、图例名  
11  theme_主题()           # 非数据元素
```

核心骨架： `ggplot(data, aes(...)) + geom_*()`

本项目扩展： `scale_*()`、`facet_*()`、`coord_*()`、`labs()`、`theme_*()`

图层	回答的问题	本项目函数
data	使用哪份数据?	<code>ggplot(data = ...)</code>
mapping	变量映射到哪里?	<code>aes(x, y, fill)</code>
geom	用什么图形表达?	<code>geom_col()</code>
stat	数据是否需要统计变换?	<code>stat = "identity"</code>
scale	颜色和刻度怎样显示?	<code>scale_fill_manual()</code>
facet	怎样分组比较?	<code>facet_wrap()</code>
coord	使用什么坐标系?	<code>coord_polar()</code>
labs	标题、轴名、图例名	<code>labs()</code>
theme	非数据元素怎样显示?	<code>theme_minimal()</code>

顺序有讲究

`ggplot() + geom_*` 决定“画什么”；`scale_*`、`facet_*`、`coord_*` 决定“怎样显示”。同样的数据和几何对象，换一个坐标系，图形的含义就变了——这正是任务 4 要讨论的问题。

映射：写在 `aes()` 内

```
1 # 颜色由「死亡原因」这个变量控制
2 ggplot(before,
3         aes(x = 月份,
4             y = 死亡率,
5             fill = 死亡原因)) +
6   geom_col()
```

颜色随死亡原因变化，并自动生成图例。

属性设定：写在 `aes()` 外

```
1 # 所有柱子使用同一种固定颜色
2 ggplot(before,
3         aes(x = 月份,
4             y = 死亡率)) +
5   geom_col(fill = "steelblue")
```

所有柱子同一种颜色，不会生成图例。

【先想一想】判断题

1. `geom_col(fill = "steelblue")` 会让三类死因变成几_____种颜色？
2. `aes(fill = 死亡原因)` 中的颜色由_____决定？
3. 如果任务 4 的玫瑰图漏掉了 `fill = 死亡原因`，会发生什么？

【参考答案】

- 1. 1 种。 `fill = "steelblue"` 写在 `aes()` 外，是固定属性，与数据无关，所有柱子（扇形）同色。
- 2. 由死亡原因这个变量决定，属于变量映射，颜色随数据取值自动变化，并生成图例。
- 3. 三类死因会变成同一种颜色，读者看不出每个月的高死亡水平主要由哪类原因贡献——玫瑰图会退化成“一圈同色的柱子”，同时失去“总量 + 构成”的表达能力。

概念	颜色 / 位置由谁决定	例子
变量映射	数据变量	<code>aes(fill = 死亡原因)</code>
属性设定	你指定，与数据无关	<code>geom_col(fill = "steelblue")</code>

函数	柱高来自哪里	适用问题
geom_bar()	自动统计每类有多少行	每个类别 出现多少次 ?
geom_col()	直接使用已有的 y 变量	每类 已有数值是多少 ?

本项目已经拥有 **累计死亡人数** 和 **死亡率**，因此全部使用：

```
1 ggplot(cause_summary,  
2       aes(x = 死亡原因,  
3           y = 累计死亡人数,  
4           fill = 死亡原因)) +  
5   geom_col()           # 数据里已经有 y 值，直接用 geom_col()
```

与讲义《知识点速查卡》一致的一句话记忆

有数值就用 **col**，数条数才用 **bar**。

本项目**全项目只用一套颜色**，定义在数据准备代码里，之后任何地方都不再改动：

死亡原因**色值****外观**

可预防疾病

#BCC7C9

灰蓝

战伤

#E6BDB8

灰粉

其他原因

#777777

深灰

```
1 cause_colors <- c("可预防疾病" = "#BCC7C9", "战伤" = "#E6BDB8", "其他原因" = "#777777")
2
3 ggplot(cause_summary, aes(x = 死亡原因, y = 累计死亡人数, fill = 死亡原因)) +
4   geom_col() +
5   scale_fill_manual(values = cause_colors) # 套用统一配色
```

表达红线：不要覆盖 `cause_colors`

要**自选**颜色时（例如巩固提升的进阶任务），请另起一个变量名，例如 `my_colors`：

```
1 my_colors <- c("可预防疾病" = "#3B7EA1", "战伤" = "#C4622D", "其他原因" = "#6E6E6E")
```

一旦覆盖 `cause_colors`，后面任务的配色会跟着变，“**同一类死因在所有图里颜色相同**”就断了。

分面把一张图拆成**结构相同**的多个小图，让小图之间可以直接比较。

```
1 ggplot(nightingale_long, aes(x = 月份, y = 死亡率, fill = 死亡原因)) +
2   geom_col() +
3   facet_wrap(~ 阶段, ncol = 2)      # 按阶段拆成两张小图
```

要点	做法	原因
纵轴尺度	scales = "fixed" (默认)	尺度不一致，柱高就不可比
月份顺序	两个阶段都用 4 月 → 次年 3 月	便于逐月对照
颜色含义	两个面板都用 cause_colors	同一颜色必须是同一死因

一句话

分面 = 同样的图形结构 + 同样的尺度 + 不同的分组。 少了任何一条，比较就不成立。

玫瑰图 = 柱形图 + 极坐标 + 平方根尺度。

等角扇形的面积满足 $A = \frac{1}{2} \cdot \theta \cdot r^2$ 。要让面积与死亡率成正比，半径必须按死亡率的平方根缩放：

```
1 p4_rose <- p4_base +  
2   scale_y_sqrt() +      # 半径 = √数值，使面积对应数值  
3   coord_polar()         # 直角坐标 → 极坐标
```

又因为三类死因是叠加画的，第 k 类死因所占扇环的面积为

$A_k = \frac{1}{2} \cdot \theta \cdot (r_k^2 - r_{k-1}^2) = \frac{1}{2} \cdot \theta \cdot d_k$ (θ = 每月所占角度, d_k = 第 k 类死因当月死亡率)

【先想一想】

1. 柱形图用什么表达数值？玫瑰图用什么表达数值？
2. 如果把半径的倍数直接当成死亡率的倍数，会犯什么错？
3. 既然面积编码这么绕，为什么南丁格尔还要用它？

【参考答案】

- 1. 柱形图用**高度（长度）**表达数值；玫瑰图用**扇形面积**表达数值。
- 2. 面积与半径是**平方关系**：半径放大 2 倍，面积会放大到 4 倍。把半径倍数读成死亡率倍数，会把差异**系统性夸大**。
- 3. 因为她的读者是议员与公众，不是统计人员。**角度 + 面积能一眼看出“整体反差”**，柱形图却要逐月比高矮——玫瑰图牺牲精确性，换来传播力。

用 1855 年 1 月的实际数据验证（ d_k 为该类死因的死亡率）：

死亡原因	d_k	扇环面积比
可预防疾病	1022.8	1022.8
战伤	30.7	30.7
其他原因	120.0	120.0

结论：每一类死因扇环的面积，恰好与它自己的死亡率成正比。前提：必须用 `scale_y_sqrt()`，且三类死因共用同一个军队人数作分母。

概念	含义	本项目中的例子
变量映射	颜色 / 位置由 数据变量 决定	<code>aes(fill = 死亡原因)</code>
属性设定	颜色 / 大小由 你指定 ，与数据无关	<code>geom_col(fill = "steelblue")</code>
指标	用什么数字回答问题	累计死亡人数（负担） / 年化死亡率（风险）

代码解释关卡（两人一组，轮流解释）：

- `data` 指定了什么？
- `aes()` 建立了哪些映射？
- `geom_col()` 为什么适合本任务？
- 如果把 `fill = 死亡原因` 移到 `aes()` 外，会发生什么？

通过标准：不看讲义，用自己的语言说明每一行代码。

项目任务

项目背景 新知探究 **项目任务** 项目总结

环节	任务	当前问题	证据图
任务 1	认识数据、选指标	哪一类死亡原因造成的死亡 负担 最重？	累计死亡人数对比图
任务 2	换月度视角	高死亡水平是否 集中 在个别月份 ？	月度堆叠柱形图
巩固提升	三星分层	变化是否一致？怎样改进表达？	★ / ★★★ / ★★★★★

第一课时的重点：完成“ **分类比较**” 与“ **月份变化**” 两个层次的证据构建。

分析目的 数据映射 图形建构 图表解读

任务1：哪类死因的负担最重

【先想一想】任务1 的分析目的

主要问题：卫生改革前这 12 个月里，三类死因各自累计死亡多少人，谁的死亡负担最重？

我要比较的是： _____

我要比较的变量是： _____

我的预测：负担最重的是 _____，理由是 _____

决策问题	本任务的选择
比较对象	可预防疾病、战伤、其他原因
比较指标	累计死亡人数 （12 个月合计）
使用数据	<code>before</code> （改革前 12 个月）
图形受众	没有统计基础的政府官员

任务1：分析目的（参考答案）

【参考答案】

比较对象：改革前 12 个月里，三类死因各自累计的死亡人数。

比较变量：死亡原因（分类变量）与累计死亡人数（数值变量）。

为什么用“人数”而不是“死亡率”？ 任务 1 问的是“**负担**”——12 个月一共死了多少人。负担是**规模**问题，直接相加即可回答；风险才是“率”的问题（留到任务 2）。

提示	说明
数据要分组	按 死亡原因 分组后 summarise() 求和
图形要表达“多少”	柱高直接对应累计死亡人数
结论要带数字	指出最高者、它的数值与占比

任务1：变量如何进入图形

【先想一想】补全映射表

把每个数据变量放到它应该去的视觉通道上。

数据变量	视觉通道	ggplot2 写法
死亡原因	横轴位置	x = _____
累计死亡人数	柱形高度	y = _____
死亡原因	填充颜色	fill = _____

选 `geom_col()` 的理由：数据里已经有 `累计死亡人数`，柱形高度**直接使用**该数值，不需要再统计计数。

任务1：数据映射（参考答案）

数据变量	变量类型	视觉通道	ggplot2 写法
死亡原因	分类变量	横轴位置	<code>x = 死亡原因</code>
累计死亡人数	数值变量	柱形长度（高度）	<code>y = 累计死亡人数</code>
死亡原因	分类变量	填充颜色	<code>fill = 死亡原因</code>

注意： `fill = 死亡原因` 与 `x = 死亡原因` 是同一个变量


同一个变量可以同时映射到多个通道。这里它既决定柱子位置，也决定柱子的颜色——**颜色并不提供额外信息，只是让三类死因更容易区分**，所以本图可以隐藏图例。

任务1：图形建构（先自己补全）

```
1 # 先按死亡原因汇总，再画图
2 cause_summary <- before %>%
3   group_by(死亡原因) %>%
4   summarise(累计死亡人数 = sum(死亡人数),
5             平均死亡率 = mean(死亡率), .groups = "drop") %>%
6   mutate(占比 = 100 * 累计死亡人数 / sum(累计死亡人数))
7
8 p1 <- ggplot(
9   data = cause_summary,
10  aes(x = ____, y = ____, fill = ____))
11 ) +
12   geom_col(width = 0.7) +
13   scale_fill_manual(values = cause_colors) +
14   labs(
15     title = "_____",
16     subtitle = "1854 年 4 月-1855 年 3 月，共 12 个月",
17     x = NULL, y = "_____", fill = "死亡原因"
18   )
19 p1
```

提示：标题要说明“什么范围、什么指标”；纵轴标签必须带单位（人）。

任务1：图形建构（参考答案）



代码解释关卡： `data` 指定了什么？ `aes()` 建立了哪些映射？ `geom_col(width = 0.7)` 做了什么？为什么 `width` 只影响外观、不影响比较？

任务1：图表解读（先写结论）

【先想一想】用证据回答问题

结论：死亡负担最重的是_____。

证据：累计死亡_____人，占全部死亡的_____%。

局限：该图只反映 12 个月的合计，不能说明_____。

读图时按三个问题依次回答：

1. 谁最高？
2. 高多少？（给出数值与占比）
3. 这张图还不能说明什么？

任务1：图表解读（参考答案）

【参考答案】

结论：卫生改革前，死亡负担最重的是**可预防疾病**。

证据：累计死亡 **11157** 人，占全部死亡（13294 人）的 **83.93%**；战伤 772 人（5.81%），其他原因 1365 人（10.27%）。

局限：该图把 12 个月合并成一个数，**看不出死亡集中在哪些月份**，也看不出改革后是否变化。

追问：只看总人数够吗？

不够。总人数把 12 个月“抹平”了。如果高死亡集中在少数几个月，就必须换一个月度视角——这正是任务 2 要解决的问题。

任务2：高风险是否集中在个别月份

【先想一想】任务2 的分析目的

主要问题：改革前这 12 个月里，哪些月份的死亡水平较高？它们是否相邻？主要由哪类死因贡献？

本任务观察的时间单位是 _____，使用的指标是 _____。

我判断“高值是否集中”的依据是： _____

我的预测：最高的月份是 _____，它应该在 _____ 季。

从任务1 到任务2	需要增加的分析维度
哪些月份的死亡水平较高？	月份
高死亡主要由什么原因造成？	死亡原因
每月的总体死亡水平是多少？	同月三类死因的死亡率之和

任务2：分析目的（参考答案）

【参考答案】

时间单位：月份；**指标：**当月三类死因合计的年化死亡率。

判断依据：把 12 个月的“月合计死亡率”排序，看最高的 3 个月在时间上是否**连续**。

关键决策：任务 1 用“人数”看负担，任务 2 必须换成“**年化死亡率**”看风险——因为各月军队人数不同，直接比较人数会被分母干扰。

同月三类死因为什么可以相加？

同一个月里，三类死因共享**同一个军队人数**作分母，所以它们的年化死亡率可以叠加，柱子的总高度就是“当月整体死亡风险”。

任务2：月份、死亡率与死因

需要表达的信息	使用变量	视觉通道	ggplot2 写法
月份先后	月份	横轴位置	<code>x = 月份</code>
某月某类死因的死亡水平	死亡率	柱形高度	<code>y = 死亡率</code>
不同死因的贡献	死亡原因	填充颜色	<code>fill = 死亡原因</code>


使用**堆叠柱形图**（`geom_col()` 的默认位置）：

- 柱子的总高度 = 当月三类死因合计的年化死亡率
- 每种颜色 = 一类死因的贡献
- 读图顺序：**先看总高度，再看颜色构成**

任务2：月度构成图（先自己补全）

```
1 p2 <- ggplot(  
2   data = _____, # 提示：使用改革前的数据  
3   aes(x = _____, y = _____, fill = _____)  
4 ) +  
5   geom_col() +  
6   scale_fill_manual(values = cause_colors) +  
7   labs(  
8     title = "_____",  
9     subtitle = "改革前：1854 年 4 月-1855 年 3 月",  
10    x = NULL, y = "_____", fill = "死亡原因"  
11  )  
12 p2  
13  
14 # 再找出月合计死亡率最高的 3 个月  
15 n_high <- before %>%  
16   group_by(日期, 月份) %>%  
17   summarise(月合计死亡率 = sum(死亡率), .groups = "drop") %>%  
18   slice_max(order_by = _____, n = 3, with_ties = FALSE) %>%  
19   arrange(日期)  
20 n_high
```

任务2：月度构成图（参考答案）



最高的 3 个月	第 1 高	第 2 高	第 3 高
日期	1854-12	1855-01	1855-02
月合计死亡率（每千人年）	721.2	1173.5	979.2

最高的是 1855 年 1 月（1173.5）；最低的 1854 年 6 月仅 7.2，两者相差约 1166.3。

任务2：月份模式与死亡构成

【先想一想】证据接力

每组说一句话，后一组必须引用前一组的证据：

1. **描述**：最高的月份是 _____。
2. **比较**：它明显高于 _____。
3. **构成**：高值主要由 _____ 死亡构成。
4. **边界**：图中还不能说明 _____。

分层任务：

- **★ 基础** 找出最高月份和主要死因
- **★★ 进阶** 比较“人数图”与“死亡率图”是否得出相同结论
- **★★★ 挑战** 说明为什么**不同月份**的死亡率可以直接比较

任务2：图表解读（参考答案）

【参考答案】

描述：最高的月份是 **1855 年 1 月**（月合计年化死亡率 **1173.5** 每千人年）。

比较：它明显高于同期的其他月份——最低的 1854 年 6 月仅 7.2，相差约 1166.3。

构成：高值月份**相邻**，集中在 **1854 年 12 月—1855 年 2 月这三个连续的冬季月**；柱形绝大部分由 **可预防疾病**（灰蓝）构成——1855 年 1 月可预防疾病的年化死亡率达 **1022.8**，占该月合计的八成以上，同期战伤仅 30.7、其他原因 120.0。

边界：数据缺少**气温、营地密度、士兵病史**等信息，不能确认高值的成因。

基础任务必做，进阶与挑战任务按自己的学习情况选做。所有图形继续使用**统一配色** `cause_colors`。

星级	任务	用到的新函数	对应讲义
★ 基础	三类死因的月度变化是否一致？ 分开 呈现	<code>facet_wrap()</code>	巩固提升 ★
★★ 进阶	为上一张图 自选三种填充颜色	<code>scale_fill_manual()</code>	巩固提升 ★★
★★★ 挑战	为任务 1 的图加上 数值标签	<code>geom_text()</code> + <code>expand</code>	巩固提升 ★★★

自选配色前必读

自选颜色请**另起变量名**（如 `my_colors`），不要覆盖 `cause_colors`——后面任务 3、任务 4 还要用它做跨图对照。

巩固提升 ★：三类死因分开看

【先想一想】★ 基础任务

三类死因的死亡率是否都随月份变化？最高值是否出现在同一个月？


在 `p2` 的基础上添加分面，把三类死因**分开**呈现，并保持**相同的纵轴尺度**。

分面变量是 _____；保持相同尺度的参数是 _____（默认值 / `scales = "free"`）。

我的发现： _____

提示： `facet_wrap(~ 死亡原因, ncol = 3, scales = "fixed")` —— `fixed` 表示所有小图共用同一套纵轴刻度，这样柱高才可比。

巩固提升 ★（参考答案）



【参考答案】

三者的变化并不一致，峰值也不在同一个月。

- **可预防疾病**：明显的冬季高峰，1855 年 1 月最高（1022.8）
- **战伤**：1854 年 11 月出现峰值（115.8）后迅速回落
- **其他原因**：整体波动小得多，最高也只在 140 左右

结论：把三类死因混在一张堆叠图里，会被“最高的那一类”掩盖差异；**分面之后，各自的节奏才看得出来。**

巩固提升 ★★：自定义配色


【先想一想】★★ 进阶任务

为上面那张分面图自选三种填充颜色，让不同死因更容易区分。

```
1 # 自选三种颜色填进来，注意不要覆盖 cause_colors
2 my_colors <- c("可预防疾病" = "_____", "战伤" = "_____", "其他原因" = "_____)
3
4 p_month_custom <- p_month + scale_fill_manual(values = _____)
5 p_month_custom
```

改完配色后，**柱高、峰值月份、分析结论**有没有变？ _____

巩固提升 ★★（参考答案）



【参考答案】

```
1 my_colors <- c("可预防疾病" = "#3B7EA1", "战伤" = "#C4622D", "其他原因" = "#6E6E6E")
2 p_month_custom <- p_month + scale_fill_manual(values = my_colors)
```

`scale_fill_manual()` 只改变**外观**：柱高、峰值月份和分析结论都不变。

关键点：换配色时另起变量名（`my_colors`），`cause_colors` 保持原值——**任务 3、任务 4 的配色才不会被带偏**。也就是说，配色是**属性层**的决策，不能污染**映射层**的约定。

巩固提升 ★★★：给图形加数值标签


【先想一想】★★★ 挑战任务

为任务 1 的 `p1` 添加三类死因的累计死亡人数标签，并与 `cause_summary` 核对。

```
1 p1_labeled <- ggplot(cause_summary,  
2                       aes(x = 死亡原因, y = 累计死亡人数, fill = 死亡原因)) +  
3   geom_col(width = 0.7) +  
4   scale_fill_manual(values = cause_colors) +  
5   _____(aes(label = _____), vjust = -0.5, size = 4) +  
6   _____(expand = expansion(mult = c(0, 0.12))) # 顶部留白  
7 p1_labeled
```

两个空分别填什么？为什么**必须**加“顶部留白”这一步？_____

巩固提升 ★★★ (参考答案)



【参考答案】

```
1 geom_text(aes(label = 累计死亡人数), vjust = -0.5, size = 4) +  
2 scale_y_continuous(expand = expansion(mult = c(0, 0.12)))
```

为什么必须加顶部留白： `geom_text(vjust = -0.5)` 把标签放在柱顶**上方**，而 ggplot 默认的坐标轴留白很小，11157 的标签会被裁掉。 `expansion(mult = c(0, 0.12))` 在纵轴顶部追加 12% 的空白，标签才完整。

核对结果： 标签值与 `cause_summary$累计死亡人数` 完全一致 (11157 / 772 / 1365) ——**图形上的数字必须能被数据核对。**

已解决的问题	用到的指标	得到的证据	关键结论
哪类死因的负担最重？	累计死亡人数	累计死亡人数对比图	可预防疾病 11157 人，占 83.93%
高死亡是否集中在个别月份？	年化死亡率	月度堆叠柱形图	集中在 1854-12—1855-02 三个连续冬季月，最高 1173.5
三类死因的变化是否一致？	年化死亡率	分面图	峰值不在同一个月，必须分开看

仍待解决：

如果改善医院与营地的卫生条件，死亡模式是否发生变化？

带着假设进入第二课时：卫生改革后，可预防疾病的死亡水平将_____。

项目任务 (续)

项目背景 新知探究 **项目任务** 项目总结

环节	任务	当前问题	证据图
任务 3	加入阶段维度	卫生改革前后 发生了什么变化 ？	按阶段分面对比图
任务 4	换一种坐标	玫瑰图适合 分析 还是 传播 ？	玫瑰图与图形取舍评价
项目总结	汇总证据	证据支持怎样的 行动建议 ？	决策建议与结论边界

第二课时的重点：**比较阶段差异，并评价不同图形的表达价值。**

回看提示：本课时会用到新知探究中的「分面」「极坐标与面积编码」两节。

任务3：改革前后发生了什么变化

【先想一想】任务3 的分析目的

主要问题：两个阶段的月度死亡水平与死因构成有什么差异？同一种死因的平均水平变化了多少？

我的假设是：卫生改革后，_____造成的死亡会 _____，
因为 _____。

我预计**变化最小**的是 _____，理由是 _____

决策问题	本任务的选择
比较对象	改革前（12 个月）与改革后（12 个月）
核心指标	年化死亡率（每千人年）
比较方法	分面 ，让两个阶段共享同一套图形结构
使用数据	<code>nightingale_long</code> （全部长表）

任务3：分析目的（参考答案）

【参考答案】

假设：卫生改革后，**可预防疾病**造成的死亡会**明显下降**，因为卫生工程切断了霍乱、痢疾、斑疹伤寒等疾病的传播路径；而**战伤**来自战斗本身，预计变化最小。

为什么这样预测？ 因为我们把“死亡原因”分成了可被卫生条件影响的和不受其影响的——**假设必须建立在变量的含义上，而不是凭感觉。**

表达红线

可以说：“**改革后观察到**可预防疾病死亡明显下降”；

不要说：“卫生改革**导致**了全部下降”、“这张图**证明**了……”。

观察到的前后差异，不等于已被证明的因果关系。

任务3：增加阶段映射

任务 2 的三个映射保持不变，再增加一个分面维度：

变量	视觉表达	ggplot2 写法
月份	横轴位置（月份先后）	<code>x = 月份</code>
死亡率	柱形高度（死亡风险高低）	<code>y = 死亡率</code>
死亡原因	填充颜色（区分死因贡献）	<code>fill = 死亡原因</code>
阶段	拆成左右两个小图对比	<code>facet_wrap(~ 阶段)</code>

分面能成立的前提


两个面板必须保持 相同的纵轴尺度、相同的月份顺序、相同的颜色含义。

只要有一条不同，读者看到的就是两张“各自为政”的图，比较就不成立。

任务3：分面对比图（先自己补全）

```
1 p3 <- ggplot(  
2   data = _____, # 提示：使用全部长表  
3   aes(x = _____, y = _____, fill = _____)  
4 ) +  
5   geom_col() +  
6   facet_wrap(~ _____, ncol = 2, scales = "fixed") +  
7   scale_fill_manual(values = cause_colors) +  
8   labs(  
9     title = "_____  
10    subtitle = "两个阶段均按 4 月至次年 3 月排列，纵轴尺度一致",  
11    x = NULL, y = "_____  
12  )  
13 p3  
14  
15 # 再量化两个阶段的平均死亡率与变化幅度  
16 stage_summary <- nightingale_long %>%  
17   group_by(阶段, 死亡原因) %>%  
18   summarise(平均死亡率 = mean(_____), .groups = "drop") %>%  
19   pivot_wider(names_from = 阶段, values_from = 平均死亡率) %>%  
20   mutate(变化幅度 = (改革后 - 改革前) / 改革前 * 100)  
21 stage_summary
```

任务3：分面对比图（参考答案）



死亡原因	改革前平均死亡率	改革后平均死亡率	变化幅度
可预防疾病	358.17	84.85	-76.31%
战伤	25.12	23.32	-7.20%
其他原因	44.41	9.51	-78.59%

任务3：变化发生在哪里

【先想一想】从图中提取证据

结论：卫生改革主要影响的是 _____，而不是 _____。

证据 1：可预防疾病的平均年化死亡率由 _____ 降到 _____（每千人年）。

证据 2：战伤由 _____ 变为 _____，基本 _____。

局限：两阶段差异还可能受到 _____ 的影响。

观察顺序：

1. 比较两个面板的整体柱高
2. 找到变化最大的颜色
3. 检查其他死因是否**同步**下降

任务3：图表解读（参考答案）

【参考答案】

结论：卫生改革主要影响的是**可预防疾病**，而不是**战伤**。

证据 1：可预防疾病的平均年化死亡率由 **358.17** 降到 **84.85**（每千人年），降幅约 **76.31%**。

证据 2：战伤由 **25.12** 变为 **23.32**，基本**持平**（仅降 7.20%）。

局限：两阶段差异还可能受到**季节变化、作战强度、军队规模与兵员构成、其他并行措施**的影响，不能完全归因于卫生改革。

进一步说明：既要**看相对变化**，也要**看绝对量级**

“其他原因”降幅最大（-78.59%），但它的**绝对量很小**（44.41 → 9.51），对总体死亡负担的影响远小于可预防疾病。

判断“改革主要影响了什么”时，**相对变化与绝对量级**必须一起看。

任务3：寻找反证

一半小组寻找“**支持卫生改革有效**”的证据，另一半寻找“**仍需谨慎**”的证据。

支持证据	谨慎证据
哪类死亡下降最明显？降幅多少？	数据还缺少哪些影响因素？
两个阶段的总体水平怎样变化？	季节变化、作战强度是否可能影响结果？
改革前后时间是否相邻、可比？	能否区分每一项卫生措施各自的作用？

汇报要求

每个观点必须指向图中的**具体位置**或**具体数据变量**，不能只说“我觉得”。

任务4：玫瑰图适合分析还是传播

【先想一想】任务4 的分析目的

主要问题：面向“精确分析”与面向“公众展示”两种目的，柱形图与玫瑰图各有什么优势和限制？

面向**分析人员**，我需要图形帮我比较_____。

面向**普通公众**，我需要图形帮读者感受_____。

我的预判：分析报告用_____，公众展示用_____。

- 1858 年，南丁格尔用**两个并排的扇形图**说服了英国议会
- 本任务使用与任务 3 **完全相同**的数据（`nightingale_long`，24 个月 × 3 类死因）、相同指标、相同数值范围
- **本任务不是找“最好看的图”，而是判断“哪幅图更适合当前目的”**

任务4：分析目的（参考答案）

【参考答案】

面向分析人员：需要比较**各月份之间精确的数值高低与差值**，以及每个月由哪类死因主导。

面向普通公众：需要帮助读者感受“**改革前后死亡风险的整体反差**”这一整体效果。

预判：分析报告用**柱形图**（柱高与数值线性对应，不易误读）；公众展示可考虑**玫瑰图**（整体形状反差醒目），但必须说明扇形面积的含义。

公平比较的前提

两张图必须使用**同一份数据、同一个指标、同一个数值范围**。只要有一项不同，比较就变成了“两张不同的图”，而不是“两种表达方式”。

任务4：坐标系改变，映射保持

数据或设置	柱形图中的表达	玫瑰图中的表达
月份	横轴位置	圆周角度 （一个圆 = 12 个月）
死亡率	柱形高度 （与数值成正比）	扇形面积 （半径按平方根缩放）
死亡原因	填充颜色 <code>fill = 死亡原因</code>	填充颜色 <code>fill = 死亡原因</code> （叠加成扇形）
阶段	分面为左右两个小图	两个极坐标圆并排
<code>cause_colors</code>	让同一死因在两张图中颜色一致	同上，保持两图可对照

不要漏掉 fill


如果玫瑰图漏掉 `aes(fill = 死亡原因)`，所有扇形同色，**看不出每个月的高死亡水平由哪类原因贡献**——玫瑰图会退化成“一圈同色的柱子”。

任务4：玫瑰图（先自己补全）

```
1 p4_base <- ggplot(  
2   data = nightingale_long,  
3   aes(x = 月份, y = 死亡率, fill = 死亡原因)  
4 ) +  
5   geom_col(width = 1, colour = "white") +  
6   scale_fill_manual(values = cause_colors) +  
7   facet_wrap(~ 阶段, ncol = 2, scales = "fixed") +  
8   labs(x = NULL, y = "年化死亡率（每千人年）",  
9        title = "改革前后各月三类死因的死亡风险（柱形表达）")  
10  
11 p4_rose <- p4_base +  
12   _____() +      # 填入纵轴尺度函数：使扇形面积对应死亡率  
13   _____() +      # 填入极坐标函数：保留月份作为角度方向  
14   labs(  
15     title = "复刻经典：南丁格尔玫瑰图（改革前后各月三类死因）",  
16     subtitle = "扇形面积表示月死亡率，颜色表示死亡原因",  
17     y = NULL  
18   )  
19 p4_rose
```

先运行 `p4_base` 看清柱形表达，再补全两个函数，观察“形状”变了而“数据”没变。

任务4：玫瑰图（参考答案）



关键变化

```
coord_polar()
```

```
scale_y_sqrt()
```

```
facet_wrap(~ 阶段, ncol = 2)
```

作用

把直角坐标换成极坐标，月份变成圆周角度

纵轴平方根变换，让**扇形面积**对应死亡率

两个阶段变成两个并排的圆（经典版式）

任务4：分析图与传播图

【先想一想】六个维度做判断

先目测同一阶段任意两个月的扇形大小，再查数据核对实际差值，然后填表。

判断标准	柱形图	玫瑰图
精确比较数值与差值	_____	_____
观察月份顺序与阶段差异	_____	_____
判断哪类死因贡献最大	_____	_____
吸引非专业受众	_____	_____
误读风险	_____	_____

任务4：图表解读（参考答案）

判断标准	柱形图	玫瑰图
精确比较数值与差值	强 ：柱高与数值线性对应	弱 ：隔了平方根换算
观察月份顺序与阶段差异	强 ：横轴按月份排列	中 ：卷成圆周，起止点不直观
判断哪类死因贡献最大	中 ：堆叠段不在同一基线	强 ：三圈同心，一眼可见
吸引非专业受众	中	强
误读风险	低	高 ：常把扇形当成数值倍数

【参考答案】

- 选作分析报告：**柱形图——它与数值直接对应，比较精确、不易误读。
- 用于公众展示：**玫瑰图——须说明“面积代表死亡率、颜色代表死因”，并避免读者精确读数。
- 必须说明：**图中的**扇形面积**表示死亡率，单位为**每千人年**，**颜色**表示死亡原因。

任务4：图形选择辩论

A 组：分面柱形图

观点：政府分析报告应优先使用柱形图。
请从**精确比较、坐标尺度、误读风险**三个方面提出证据。

B 组：玫瑰图

观点：面向公众传播时可以优先使用玫瑰图。
请从**整体感知、注意力、历史语境**三个方面提出证据。

共同底线

标题、单位、图例和结论边界必须完整。**换图形可以，换掉严谨性不行。**

项目总结

项目背景 新知探究 项目任务 **项目总结**

任务	解决的问题	证据图	形成的判断
任务 1	哪类死因的负担最重？	累计死亡人数对比图	确定主要矛盾
任务 2	高死亡集中在哪些月份？	月度堆叠柱形图	识别时间模式
巩固提升	三类死因的变化是否一致？	分面图	分开看各自的节奏
任务 3	改革前后怎样变化？	分面对比图	比较阶段差异
任务 4	玫瑰图适合什么目的？	柱形图与玫瑰图	评价图形选择

项目结论来自多幅图的相互支持，而不是一幅“好看的图”

【先想一想】把证据组织成一段结论

结论：改革前，_____是士兵死亡的主要原因；改革后，_____。

建议：有限资源应优先用于_____, 同时保留必要的战伤救治。

证据：任务 1、任务 2、任务 3 分别从_____, _____和_____提供支持。

局限：数据没有记录_____, 因此不能把全部变化简单归因于卫生改革。

科学表达包含两部分：**说清证据支持什么，也说清证据不能证明什么。**

【参考答案】约 240 字

结论：改革前（1854 年 4 月—1855 年 3 月）英军死亡负担以**可预防疾病**为主，共 **11157** 人，占 **83.93%**；死亡风险在冬季高度集中，1855 年 1 月的月合计年化死亡率达 **1173.5**（每千人年）。

证据：改革前后对比，可预防疾病的平均年化死亡率由 **358.17** 降至 **84.85**，降幅约 **76.31%**；同期战伤仅由 25.12 变为 23.32（-7.20%），基本持平。

建议：应优先重视**病区环境卫生与疾病防控**，并继续监测季节性疾病高发月份；战伤救治需单独安排资源。

图形选择：分析用**分面堆叠柱形图**（柱高与数值直接对应）；公众传播可考虑**玫瑰图**，但须说明扇形面积的含义。

局限：数据缺少气温、营地密度、兵员构成等信息，也缺少平行对照，两阶段差异不能完全归因于卫生改革。

步骤 本项目中的决定

- 1 从公共卫生决策中提出真实问题
- 2 认识数据并选择可比较的**指标**
- 3 建立**变量** → **视觉通道**的映射
- 4 用 ggplot2 图层**构建图形**
- 5 从图中提取**证据**并检验自己的预测
- 6 比较不同**图形**的表达价值
- 7 形成**建议**，同时说明局限

一句话

ggplot2 提供绘图规则，**分析目的决定使用哪些规则。**

AI 可以帮你

- 解释报错和函数参数
- 比较两段代码的差异
- 提出标签、配色和布局建议

必须由你完成

- 明确分析目的、选择指标
- 设计变量与视觉通道的映射
- 解释关键代码
- 核验图形与结论是否一致

AI 使用原则

使用 AI 本身**不加分**，**能否核验**才加分。

可选提示词：“ 请检查我的图表、数值与结论，指出单位、比较范围、面积编码和因果措辞上的问题，最多两处，并给出核验方法，不要补充我未提供的数值。”

评价维度	权重	评价证据
问题与分析目的	15%	每个任务的分析设计
指标与数据映射	20%	变量—视觉通道映射表
代码与图形表达	25%	可运行代码、标题、单位和图例
证据与结论	25%	图表解读、建议与局限
协作、反思与责任	15%	互动记录、AI 核验日志

提交物： `.qmd` 源文件、渲染后的 HTML、项目指导书（空白版 + 内容版）和 AI 使用记录。

新的真实问题：

宁波舟山港不同货物类型的吞吐量有何差异？近年来港口货运结构发生了怎样的变化？

迁移要求（顺序不能颠倒）：

1. 先写**分析目的**和**目标受众**
2. 选择**总量、比例或增长率**中的哪一个作为指标，并说明理由
3. 完成**变量—视觉通道映射表**
4. 用柱形图或分面图**构建证据**
5. 写出**结论、建议和局限**

分析设计先于代码和图形

1. 什么是 ggplot2 的**图形语法**?
2. 为什么图形选择必须从**分析目的**出发?
3. 南丁格尔案例说明数据可视化怎样**影响公共决策**?

请在出口卡上写下:

- 今天最重要的一项**收获**
- 仍然不确定的一个**问题**
- 下一次项目中准备改进的一项**做法**

回到那条链:

真实问题 → 明确分析目的 → 选择指标 → 建立映射 → 构建图形 → 解读证据 → 形成建议